

CCDS

(prediction-oriented)

Ma ChengYuan

CCDS

interface : telegram


language : python

database : mongodb

motivation : To support doctor by prediction and possible factors

goal : To reduce the diagnosis time in order to offer faster and more accurate treatment and relieve labourious workload for medical staffs

pipeline



datasets intro

datasets :

Based on

epiz_inform_stationary_risks_10_events.csv

1.final_obj_hospitalization.txt

- personal info

2.from all_episodes_risks_strat.pkl –

- operation code
- diagnosis

3.all_analisis_risk_stratif.txt

- test result

target disease :

- 1) Желудочковая тахикардия
- 2) Острый коронарный синдром
- 3) Медиастинит
- 4) ОНМК

feature info

feature info :

Клинический_диагноз_рубрика : 723

Код_МЭС : 611

Код_теста : 2469

patients number by target :

желудочковая_тахикардия : 1723

острый_коронарный_синдром : 712

медиастинит : 46

онмк : 437




basic data distribution




order by target as below :




- желудочковая_тахикардия
- острый_коронарный_синдром
- медиастинит
- ОНМК




graph showed from top to bottom:

- gender
- age
- blood type









preprocessing

1. select potential columns from each df
2. find target disease from epiz_inform_stationary_risks_10_events , and insert extra column to classify patient's disease
3. convert categorization value to numerical value using one-hot encoding
4. merge dfs

all_analysis_risk_stratif:

- Код_теста
- 1) fill null cell in col('Значение_число') with average value from criteria ((lower + upper) / 2)

clinical_diag_293_strat_risk:

- Код_МЭС
- Клинический_диагноз_рубрика

model training

1. all_analysis_risk_stratif:

- Код_теста

test sets :

- 1) numerical value using col('Значение_число') with average value in null cell
- 2) classified into lower & higher of criteria
- 3) without value in null cell
- 4) numerical columns of echo data included , without value in null cell

2. clinical_diag_293_strat_risk:

- Код_МЭС
- Клинический_диагноз_рубрика

training result(1)

1)

row x column :
4909x3121

желудочковая_тахикардия
: 1359

острый_коронарный_синдром
: 595

медиастинит
: 36

ОНМК
: 340

1) original

желудочковая_тахикардия :
Neural Net : f1 : 0.567878
xgb : f1 : 0.693428

острый_коронарный_синдром :
Neural Net : f1 : 0.592496
xgb : f1 : 0.759434

медиастинит :
Neural Net : f1 : 0.498126
xgb : f1 : 0.498126

ОНМК :
Neural Net : f1 : 0.510228
xgb : f1 : 0.599690

1) oversample

желудочковая_тахикардия :
Neural Net : f1 : 0.566822
xgb : f1 : 0.679563

острый_коронарный_синдром :
Neural Net : f1 : 0.574827
xgb : f1 : 0.754864

медиастинит :
Neural Net : f1 : 0.483158
xgb : f1 : 0.498126

ОНМК :
Neural Net : f1 : 0.420461
xgb : f1 : 0.618609

1) cross validation

желудочковая_тахикардия :
xgb : f1 : 0.684981

острый_коронарный_синдром :
xgb : f1 : 0.742531

медиастинит :
xgb : f1 : 0.52202

ОНМК :
xgb : f1 : 0.59033

training result(2)

2)

row x column :
4909x3435

желудочковая_тахикардия
: 1359

острый_коронарный_синдром
: 595

медиастинит
: 36

онмк
: 340

2) original

желудочковая_тахикардия :
Neural Net : f1 : 0.671587
xgb : f1 : 0.688900

острый_коронарный_синдром :
Neural Net : f1 : 0.725524
xgb : f1 : 0.691100

медиастинит :
Neural Net : f1 : 0.497954
xgb : f1 : 0.497954

онмк :
Neural Net : f1 : 0.589569
xgb : f1 : 0.602336

2) oversample

желудочковая_тахикардия :
Neural Net : f1 : 0.636534
xgb : f1 : 0.694334

острый_коронарный_синдром :
Neural Net : f1 : 0.702459
xgb : f1 : 0.684404

медиастинит :
Neural Net : f1 : 0.544369
xgb : f1 : 0.569381

онмк :
Neural Net : f1 : 0.602206
xgb : f1 : 0.589569

2) cross validation

желудочковая_тахикардия :
xgb : f1 : 0.693104

острый_коронарный_синдром :
xgb : f1 : 0.69856

медиастинит :
xgb : f1 : 0.498106

онмк :
xgb : f1 : 0.610675

training result(3)

желудочковая_тахикардия :

xgb :

f1 : 0.693428

decsiontree :

f1 : 0.640268

LGB :

f1 : 0.686466

catboost :

f1 : 0.667132

острый_коронарный_синдром :

xgb :

f1 : 0.754944

decsiontree :

f1 : 0.652398

LGB :

f1 : 0.768578

catboost :

f1 : 0.743238

медиастинит :

Neural Net :

f1 : 0.498126

xgb :

f1 : 0.498297

decsiontree :

f1 : 0.497784

LGB :

f1 : 0.498297

catboost :

f1 : 0.498297

ОНМК :

xgb :

f1 : 0.619066

decsiontree :

f1 : 0.659900

LGB :

f1 : 0.614116

catboost :

f1 : 0.536594

original from (1):

желудочковая_тахикардия

:

xgb : f1 : 0.693428

острый_коронарный_синдром :

xgb : f1 : 0.759434

медиастинит :

xgb : f1 : 0.498126

ОНМК :

xgb : f1 : 0.599690

training result(4)

желудочковая_тахикардия :
xgb :
f1 : 0.708828

острый_коронарный_синдром :
xgb :
f1 : 0.752493

медиастинит :
Neural Net :
f1 : 0.498297

ОНМК :
xgb :
f1 : 0.626451

original from (1):
желудочковая_тахикардия
:

xgb : f1 : 0.693428

острый_коронарный_синдром :

xgb : f1 : 0.759434



медиастинит :

xgb : f1 : 0.498126


ОНМК :

xgb : f1 : 0.599690

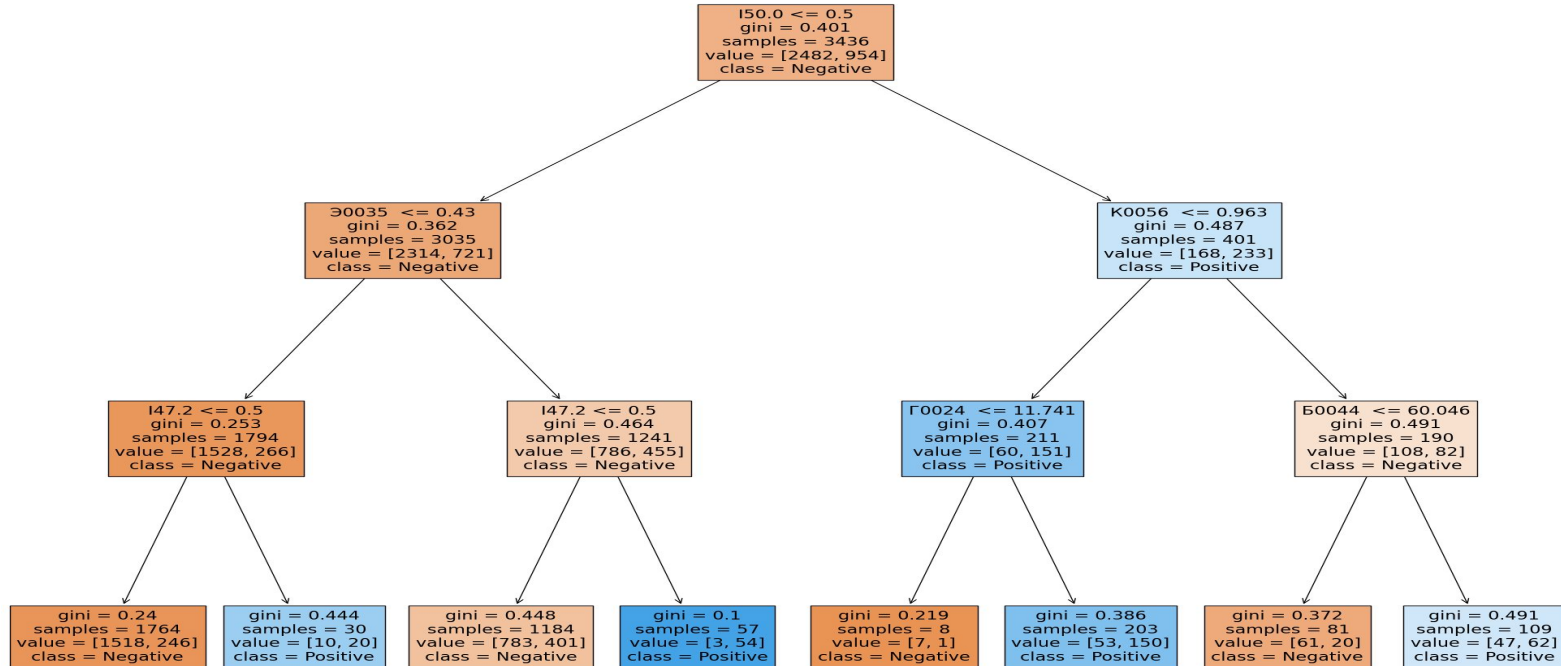
feature importance (left xgb , right shap)



feature importance (shap)(black box model)



feature importance (decision tree)



model training with feature importances(shap)

extracting columns with more than 0 shap value

original :

f1 : 0.693428

	precision	recall	f1-score	support
0	0.81	0.91	0.86	1065
1	0.65	0.45	0.53	408
accuracy			0.78	1473
macro avg	0.73	0.68	0.69	1473
weighted avg	0.77	0.78	0.77	1473

after :

f1 : 0.701943

	precision	recall	f1-score	support
0	0.82	0.90	0.86	1065
1	0.65	0.47	0.55	408
accuracy			0.78	1473
macro avg	0.73	0.69	0.70	1473
weighted avg	0.77	0.78	0.77	1473

feature selection(L2 regularization)

желудочковая_тахикардия :
total features: 3117

selected features: 963

f1 : 0.704869

острый_коронарный_синдром :
total features: 3117

selected features: 811

f1 : 0.743238

медиастинит :
total features: 3117

selected features: 696

f1 : 0.498297

ОНМК :
total features: 3117

selected features: 852

f1 : 0.593904

compared with original from
test(1):

желудочковая_тахикардия :

xgb : f1 : 0.693428

острый_коронарный_синдром :

xgb : f1 : 0.759434

медиастинит :

xgb : f1 : 0.498126

ОНМК :

xgb : f1 : 0.599690

feature selection(pearson)

X : correlation rate used to remove features
(higher rates means less feature removed)


Y : F1 score

желудочковая_тахикардия best at : 0.9

острый_коронарный_синдром best at 0.7

медиастинит best at 0.3

онмк best at 0.75



feature selection(L2 regularization after removal correlated columns)

желудочковая_тахикардия :
total features: 2415

selected features: 776

f1 : 0.678326

острый_коронарный_синдром :
total features: 1870

selected features: 580

f1 : 0.739063

медиастинит :
total features: 802

selected features: 226

f1 : 0.498126

ОНМК :
total features: 2148

selected features: 671

f1 : 0.599242

original from (1):
желудочковая_тахикардия :

xgb : f1 : 0.693428

острый_коронарный_синдром :

xgb : f1 : 0.759434

медиастинит :

xgb : f1 : 0.498126

ОНМК :

xgb : f1 : 0.599690

related previous work

желудочковая_тахикардия :

A machine learning-based risk stratification model for ventricular tachycardia and heart failure in hypertrophic cardiomyopathy

link :

<https://www.sciencedirect.com/science/article/pii/S001048252100442X>

острый_коронарный_синдром :

A Machine Learning-Based Approach for the Prediction of Acute Coronary Syndrome Requiring Revascularization

link :

<https://link.springer.com/article/10.1007/s10916-019-1359-5>

медиастинит :

Performance of a Machine Learning Algorithm in Predicting Outcomes of Aortic Valve Replacement

link :

<https://www.sciencedirect.com/science/article/abs/pii/S0003497520311565>

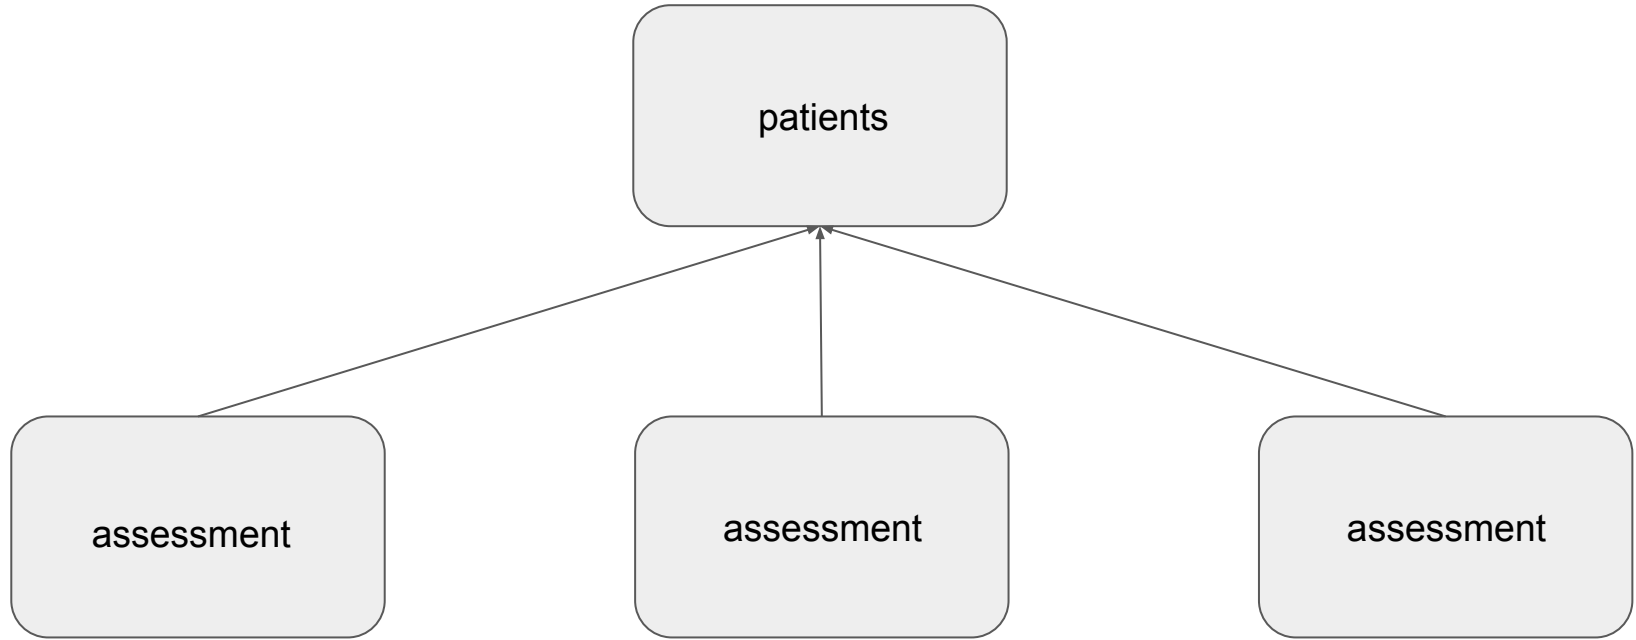
ОНМК :

Performance Analysis of Machine Learning Approaches in Stroke Prediction

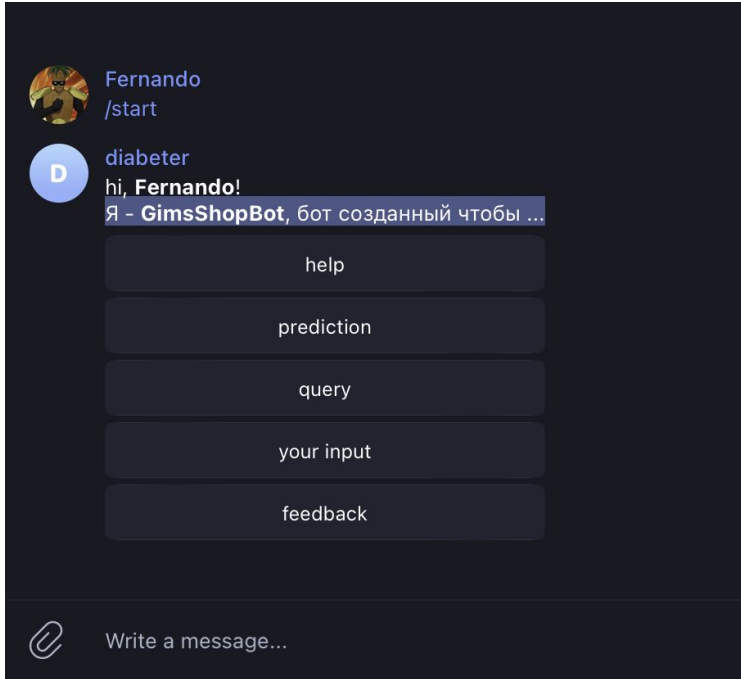
link:

https://ieeexplore.ieee.org/abstract/document/9297525?casa_token=TfM_OTIj2BEAAAAA:vV39yNcKMpzQc9jI_oopWu0eggmUj9CRoMETefwiKE7d3W07qChFVgS8HmEnqhtRvggkcX0FChDokA

database design



demo image



/help - to offer instruction

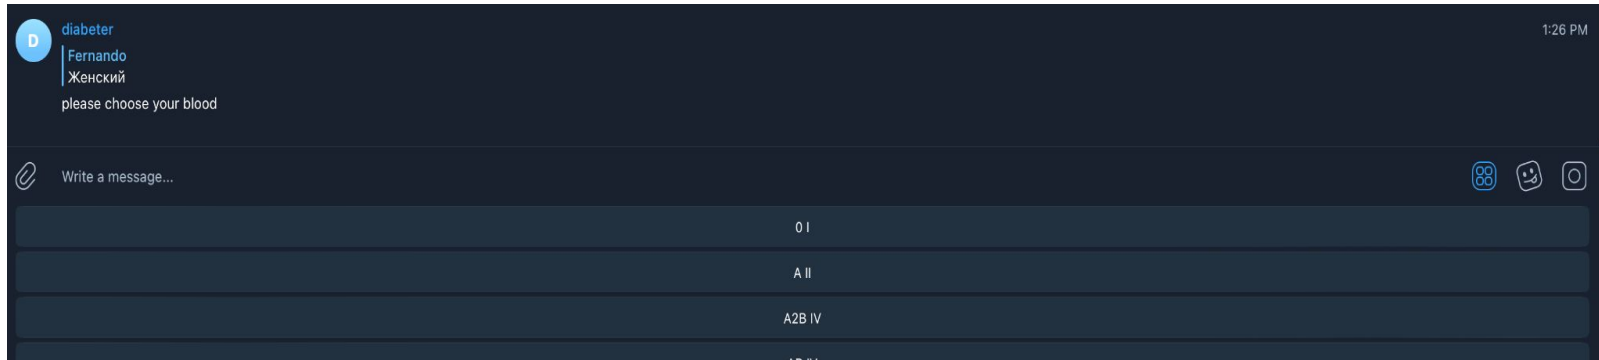
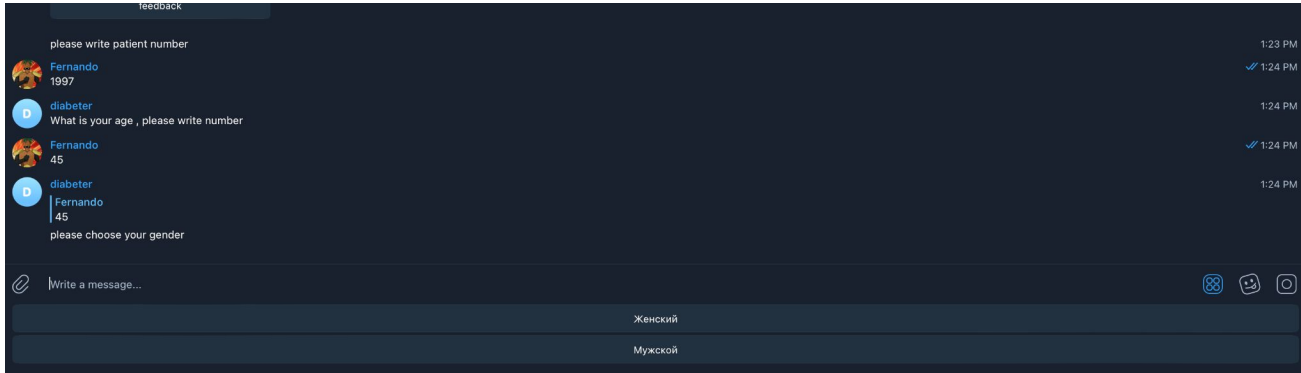
/prediction - main functionality to predict

/query - to offer the name of code

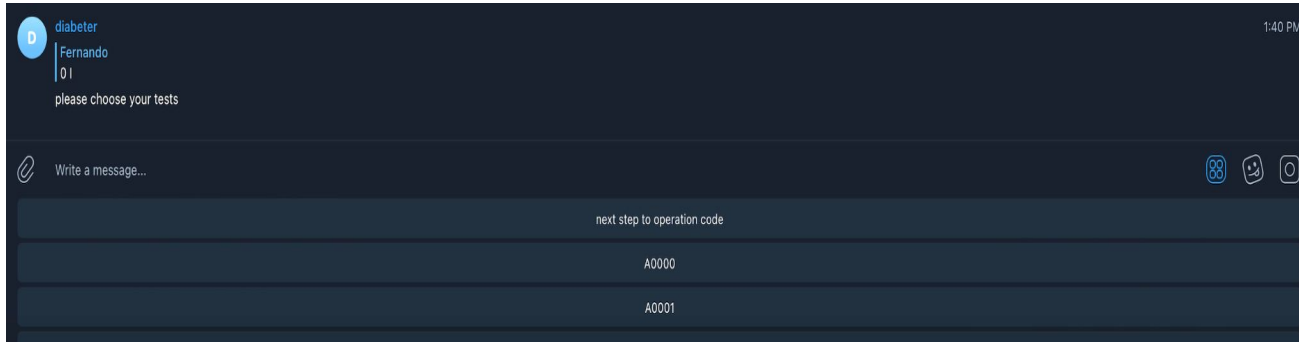
/your input - to showcase the current input

/feedback - to assess the prediction in order to trace the accuracy

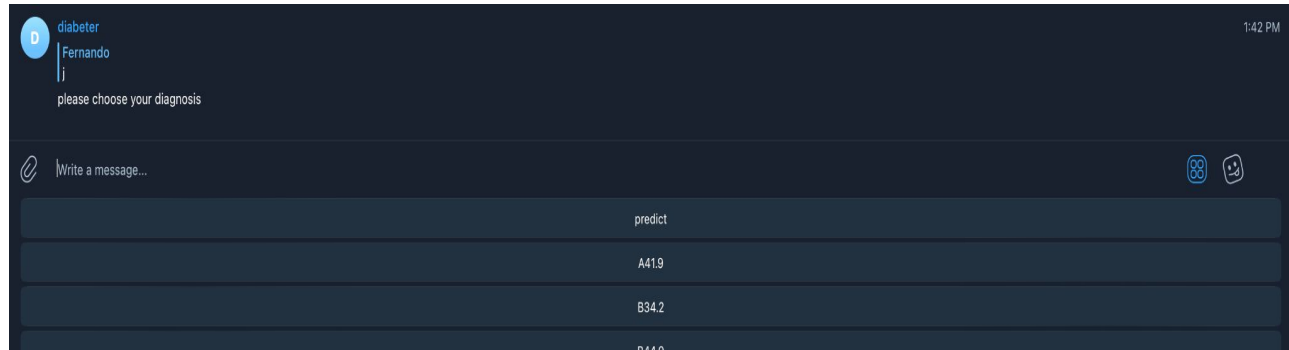
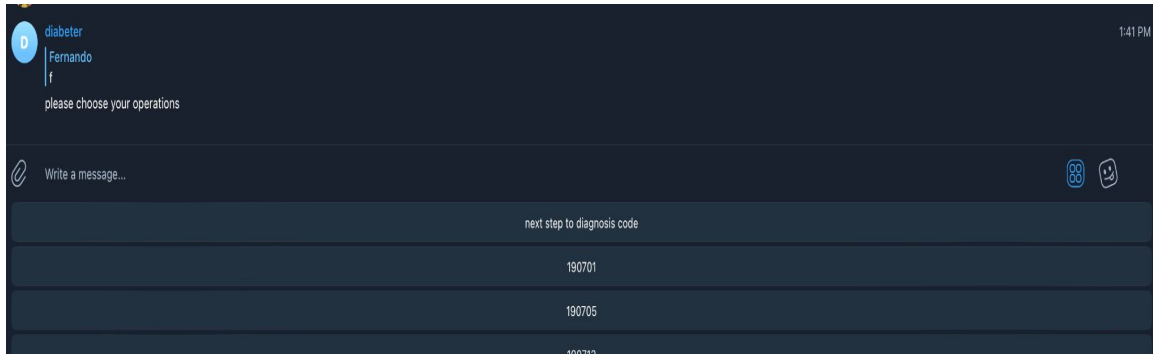
demo image



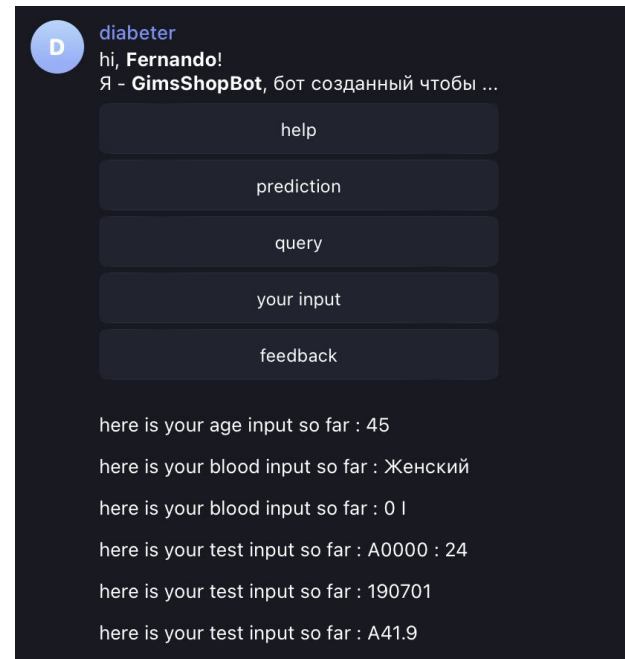
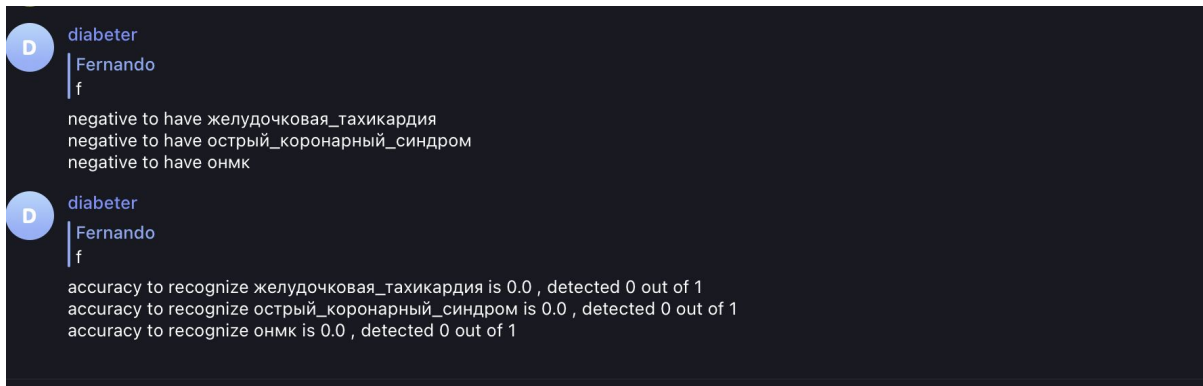
demo image



demo image



demo image



demo image

D

diabeter

Fernando

j

negative to have желудочковая_тахикардия

T09.1 <= 0.00

Д0072 <= 5.50

I08.2 <= 0.00

D37.7 <= 0.00

K57.2 <= 0.00

K83.1 <= 0.00

O0073 <= 43.50

T82.8 <= 0.00

ЛБ0046 <= 5.41

st15.018 <= 0.00

Ц0022 <= 0.00

ПЭ0083 <= 40.83

O0080 <= 19.62

Б0060 <= 0.00

M33.2 <= 0.00

further improvement

- 1) advice of treatment
- 2) implement CDS hooks
- 3) implement censorship to input in order to prevent abnormal input
- 4) implement more clear explanation instead of code
- 5) feature selection , remove correlated columns

End
(thank you very much)

Ma ChengYuan